

Modelowanie trójwymiarowej struktury chromatyny w kontekście klasyfikacji i regresji przebiegu cyklu komórkowego

Szymon Kiełtyka, Jakub Miszczak, Daminika Dzeranhouckaya, Karolina Kawulska

1. Wstęp

Współczesna biologia komórkowa intensywnie wykorzystuje metody modelowania przestrzennego w celu lepszego zrozumienia organizacji materiału genetycznego. Jednym z kluczowych zagadnień w tej dziedzinie jest badanie struktury chromatyny oraz jej zmienności w zależności od fazy cyklu komórkowego. Celem niniejszego projektu jest przypisanie komórkom ich odpowiednich faz cyklu komórkowego na podstawie dostępnych danych, a następnie odtworzenie trójwymiarowej struktury chromatyny w tych komórkach. Realizacja tych zadań pozwoli na lepsze zrozumienie zależności pomiędzy organizacją chromatyny a przebiegiem cyklu komórkowego, co może mieć istotne znaczenie zarówno w badaniach podstawowych, jak i zastosowaniach biomedycznych.

2. Dane

contact_data_2000.zip – dane dotyczące kontaktów międzykomórkowych zarówno w obrębie jednego chromosomu, jak i między chromosomowo

train_data_2000.zip – dane do trenowania modeli

test_data_2000.zip – dane walidacyjne, nie posiadają informacji o fazie komórkowej

3. Etapy projektu

Ekstrakcja cech

Korzystając z danych dotyczących kontaktów między komórkami, udało się stworzyć nowe cechy opisujące relacje z innymi komórkami. Użyliśmy w tym celu biblioteki Pandas w Pythonie. Cechy podstawowe, które wybraliśmy to m.in. :

- średnia, mediana, odchylenie standardowe wielkości regionu w pojedynczej komórce
- średnia, mediana, odchylenie standardowe odległości między dwoma komórkami w kontakcie
- suma międzychromosomowych i wewnętrznych kontaktów
- CDD – metryka CIRCLET

Przygotowany tak zbiór featurów połączyliśmy z zestawem danych treningowych dla danej komórki.

	cellid	same_chr_contacts	avg_CDD	max_region2_length	avg_region1_length	avg_symmetry_y	inter_chr_ratio_y	phase
0	SCG0088_AAAGGACGTTAACGGC-1	3179	85.231628	182	89.425013	67.493773	0.175143	G1
1	SCG0088_AAATCCGGTGACATAT-1	2296	76.904854	175	80.616243	73.302925	0.116243	S
2	SCG0088_AACAGCAAGACAGGCG-1	2165	75.102533	200	82.671569	72.911356	0.115605	G1
3	SCG0088_AACATCATCAGGTTTA-1	5228	75.700400	189	87.414566	67.384669	0.091257	S
4	SCG0088_AACCTTAAGCTGCACA-1	1965	78.906632	181	80.333188	69.832753	0.144164	NaN

Tabela 1: Przygotowana ramka danych z wybranymi featurami oraz fazą komórkową

Klasyfikacja

Przeprowadzono **wieloklasową klasyfikację faz cyklu komórkowego** (G1, S, G2M) na podstawie danych dotyczących pojedynczych komórek. W celu redukcji liczby cech zastosowano **analizę korelacji** – usunięto zmienne, których współczynnik korelacji przekraczał 0.9, aby ograniczyć redundancję i poprawić efektywność modeli.

Do klasyfikacji przetestowano trzy algorytmy:

- **Random Forest**
- **XGBoost**
- **Support Vector Machine (SVM)**

W celu poprawy wyników dla **klas mniejszościowych** (G1, S) zastosowano **oversampling metodą SMOTE**. Dla każdego z modeli przeprowadzono **optymalizację hiperparametrów z użyciem Grid Search**.

Oceny wydajności modeli dokonano przy pomocy następujących metryk:

- **Accuracy**
- **Raportu klasyfikacji** (precision, recall, f1-score)
- **Macierzy pomyłek**
- **Walidacji krzyżowej** (cross-validation)

Początkowo do klasyfikacji danych testowych wykorzystano model **XGBoost**, jednak finalnie najlepsze wyniki osiągnięto przy użyciu **klasyfikatora SVM z optymalnie dobranymi parametrami**. Model SVM uzyskał najwyższą trafność spośród wszystkich testowanych modeli – około 62% na zbiorze treningowym i 47% na zbiorze testowym – oraz dobrą jakość klasyfikacji dla dominującej klasy G2M.

	cellid	phase	order_within_phase	order
0	SCG0089_CTTATGTTCCCGCCTA-1	G2M	NaN	NaN
1	SCG0093_AGAACCGCACAGCCAT-1	G1	NaN	NaN
2	SCG0090_CCAGGATGTGCTCACC-1	G2M	NaN	NaN
3	SCG0089_TACCTTTAGCACTTGG-1	G2M	NaN	NaN
4	SCG0092_TGATCAGGTTTGAGGC-1	G1	NaN	NaN

Tabela 2: Dane testowe po uzupełnieniu kolumny 'phase'

Regresja

Kolumna **order_within_phase**

Proces uzupełniania wartości w kolumnie `order_within_phase` rozpoczęto od zastosowania różnych modeli regresyjnych. Przetestowano wiele modeli, w tym:

- **MLPRegressor** (sztuczna sieć neuronowa),
- **LinearRegression**,
- **DecisionTreeRegressor**,
- **RandomForestRegressor**,
- **XGBRegressor**,
- **KNeighborsRegressor**.

Jako kryteria oceny jakości predykcji przyjęto klasyczne metryki regresyjne:

- **MAE** – błąd bezwzględny średni,
- **RMSE** – pierwiastek z błędu średniokwadratowego,
- **R²** – współczynnik determinacji.

Spośród wszystkich badanych modeli, **najlepszy rezultat na zbiorze walidacyjnym uzyskał MLPRegressor**, przy odpowiednio dostrojonych parametrach. Osiągnięte przez niego wyniki to:

- **MAE:** 17.49
- **RMSE:** 3.41
- **R²:** 0.059

Na podstawie tego modelu uzupełniono brakujące wartości w kolumnie `order_within_phase` w zbiorze testowym.

		cellid	phase	order_within_phase	order
0	SCG0089_CTTATGTTCCCGCCTA-1	G2M		6	NaN
1	SCG0093_AGAACCGCACAGCCAT-1	G1		5	NaN
2	SCG0090_CCAGGATGTGCTCACC-1	G2M		11	NaN
3	SCG0089_TACCTTTAGCACTTGG-1	G2M		5	NaN
4	SCG0092_TGATCAGGTTTGAGGC-1	G1		6	NaN

Tabela 3: Dane testowe po uzupełnieniu kolumny 'order_within_phase'

Kolumna **order**

W celu uzupełnienia kolumny **order** zastosowano podejście regresyjne. Przetestowano następujące modele regresji:

- **MLPRegressor**,
- **LinearRegression**,
- **DecisionTreeRegressor**,
- **RandomForestRegressor**,
- **XGBRegressor**,
- **KNeighborsRegressor**.

Do oceny jakości predykcji wykorzystano standardowe metryki regresji:

- **MAE** (Mean Absolute Error),
- **RMSE** (Root Mean Squared Error),
- **R²** (współczynnik determinacji).

Spośród wszystkich testowanych modeli, najlepsze wyniki na zbiorze walidacyjnym osiągnął **Random Forest Regressor** (z najlepiej dobranymi parametrami). Osiągnięte wartości metryk to:

- **MAE:** 9.272
- **RMSE:** 11.412
- **R²:** 0.174


Model ten został wykorzystany do predykcji brakujących wartości w kolumnie **order** dla danych testowych.

	cellid	phase	order_within_phase	order
100	SCG0089_AGAATCGAGGCTAGAA-1	G2M	7	21
101	SCG0093_GAGTCAAAGGCCTGGT-1	G2M	5	20
102	SCG0090_TTAAGCCAGTTAACCA-1	G2M	8	21
103	SCG0092_GATTACTCAGGCTTCG-1	G2M	6	27
104	SCG0090_CGCCAAATCATCACTT-1	G2M	5	22
105	SCG0089_ACCCTGTTCTGAAGTGA-1	G2M	6	21
106	SCG0092_AAGGATGTCGCTATAA-1	G2M	6	21
107	SCG0088_CATCCTCAGCTTGCTC-1	G2M	7	21
108	SCG0088_TGCTTGTGTAATAGCT-1	G2M	7	21
109	SCG0088_TATCGAGGTAATGGCC-1	G1	6	21

Tabela 4: Dane testowe po uzupełnieniu kolumny 'order'

Modelowanie 3D

Końcowym etapem projektu była wizualizacja 3D struktury chromatyny. Do jej wykonania użyto modelu ChromMovie. Wykonano trzy wizualizacje: dla jednego chromosomu, dla jednej komórki, oraz dla czterech komórek. Rezultaty wizualizacji możn zobaczyć poniżej



Rysunek 1:
Wizualizacja
jednego
chromosom
u

Rysunek
2: Wizualizacja
jednej komórki



Rysunek
3:
Wizualizacja
kilku
komórek

